ADAPTIVE EXPLORATION STRATEGIES IN DEEP REINFORCEMENT LEARNING FOR TASK OFFLOADING UNDER NON-STATIONARY WORKLOADS IN MOBILE EDGE COMPUTING

SKRIPSI

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Komputer
Program Studi Informatika

Disusun oleh:
Benrycho Willyam R. Nenobais
NIM: 235314159

PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS SANATA DHARMA
YOGYAKARTA
2026

Daftar Isi

DAFTAR ISI i

BAB I PENDAHULUAN 1

1.1 LATAR BELAKANG 1

1.2 RUMUSAN MASALAH 2

1.3 BATASAN MASALAH 3

1.4 TUJUAN PENELITIAN 5

1.5 MANFAAT PENELITIAN 5

1.6 METODOLOGI PENELITIAN 6

1.7 SISTEMATIKA PENULISAN 7

DAFTAR PUSTAKA 9

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan *Internet of Things* (IoT) dan perangkat *mobile* meningkatkan kebutuhan terhadap layanan komputasi yang mampu memproses data dengan cepat. Namun, perangkat *mobile* memiliki keterbatasan sumber daya komputasi dan energi. *Mobile Edge Computing* (MEC) menjadi salah satu solusi dengan menyediakan sumber daya komputasi yang lebih dekat dengan pengguna. Melalui mekanisme *task offloading*, tugas komputasi dapat dialihkan dari perangkat *mobile* ke *edge server* sehingga berpotensi mengurangi waktu pemrosesan dan penggunaan energi [1], [2].

Meskipun demikian, keputusan *task offloading* memiliki tantangan karena harus mempertimbangkan kondisi jaringan, beban server, dan antrean tugas secara dinamis. Ketika banyak perangkat mengirimkan tugas secara bersamaan tanpa koordinasi terpusat, beban *edge server* dapat meningkat secara tiba-tiba sehingga menyebabkan keterlambatan atau tugas tidak selesai sebelum batas waktu (*deadline*). Tang dan Wong [3] mengusulkan pendekatan *Distributed Deep Reinforcement Learning* (DRL) dengan kombinasi LSTM, *Dueling* DQN, dan *Double* DQN (LSTM-D3QN) di mana setiap perangkat *mobile* mempelajari keputusan *offloading* secara mandiri berdasarkan observasi lokal dan riwayat pemanfaatan server. Pendekatan tersebut mampu mengurangi *task drop ratio* dan *average delay* dalam skenario pengujian dengan pola beban kerja yang stasioner.

Namun, kondisi *workload* dalam lingkungan MEC nyata tidak selalu tetap (*non-stationary workload*). Perubahan jumlah maupun karakteristik tugas yang datang dari waktu ke waktu dapat menggeser distribusi beban kerja dan dinamika antrean pada *edge server*. Pada algoritma DRL dengan strategi eksplorasi standar seperti ϵ-greedy, laju eksplorasi akan meluruh hingga nilai minimum seiring

berjalannya pelatihan. Akibatnya, ketika terjadi perubahan pola *workload* setelah kebijakan agen konvergen, masing-masing agen perangkat cenderung terjebak pada eksploitasi kebijakan lama yang sudah tidak optimal terhadap kondisi lingkungan saat ini. Oleh karena itu, keseimbangan *exploration* dan *exploitation* yang mampu menyesuaikan diri kembali saat lingkungan berubah menjadi faktor krusial. Zhu dkk. [4] mengembangkan *self-adjusting deep Q-learning* yang memanfaatkan ketidakpastian model (*model uncertainty*) untuk menyesuaikan eksplorasi ketika lingkungan berubah. Sementara itu, Kumar dan Singh [5] menerapkan *adaptive epsilon-greedy* pada lingkungan keamanan IoT-*Edge*. Kedua penelitian tersebut menunjukkan bahwa strategi eksplorasi adaptif berpotensi meningkatkan kemampuan adaptasi agen, tetapi belum dievaluasi pada konteks permasalahan *task offloading* MEC terdistribusi dengan perubahan pola *workload*.

Berdasarkan hal tersebut, penelitian ini berfokus pada evaluasi strategi *exploration–exploitation* dalam meningkatkan kemampuan adaptasi DRL untuk *task offloading* pada lingkungan MEC dengan *non-stationary workload*. Arsitektur LSTM-D3QN dipertahankan, sedangkan strategi eksplorasi menjadi variabel yang dibandingkan, yaitu *epsilon-greedy*, *adaptive epsilon-greedy*, dan eksplorasi berbasis ketidakpastian model (*model uncertainty*). Evaluasi dilakukan pada beberapa pola perubahan *workload* dengan memperhatikan *task drop ratio*, *average delay*, *average cost*, dan waktu pemulihan (*recovery time*). Dengan demikian, penelitian ini diharapkan dapat memberikan gambaran mengenai pengaruh strategi eksplorasi terhadap kemampuan adaptasi kebijakan DRL ketika menghadapi perubahan *workload*.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah:

1. Bagaimana pengaruh perubahan pola *workload non-stationary* terhadap kinerja algoritma LSTM-D3QN dalam melakukan *task offloading* pada lingkungan *Mobile Edge Computing*?
2. Bagaimana perbandingan kinerja strategi *epsilon-greedy*, *adaptive epsilon-greedy*, dan eksplorasi berbasis ketidakpastian model (*model uncertainty*) dalam menghadapi perubahan *workload*?
3. Strategi eksplorasi manakah yang memiliki kemampuan adaptasi terbaik berdasarkan *task drop ratio*, *average delay*, *average cost*, dan *recovery time* setelah terjadi perubahan *workload*?

1.3 Batasan Masalah

Agar penelitian lebih terarah dan tidak meluas dari tujuan yang telah ditetapkan, batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian berfokus pada permasalahan *task offloading* dalam lingkungan ***Mobile Edge Computing*** **(MEC)** dengan kondisi *workload non-stationary*.
2. Pengambilan keputusan *task offloading* menggunakan pendekatan *Distributed Deep Reinforcement Learning* yang beroperasi secara terdesentralisasi, di mana setiap perangkat *mobile* menjalankan agen pembelajaran mandiri (*independent learner*) dengan parameter jaringan dan memori pengalaman lokal masing-masing untuk menentukan keputusan *offloading* ke sumber daya komputasi yang tersedia tanpa komunikasi antar-perangkat.
3. Arsitektur algoritma yang digunakan adalah **LSTM-D3QN**. Arsitektur jaringan dan konfigurasi pembelajaran dipertahankan sama selama eksperimen sehingga penelitian berfokus pada pengaruh strategi eksplorasi.
4. Strategi eksplorasi yang dibandingkan meliputi:

- *Epsilon-greedy* sebagai strategi dasar.
- *Adaptive epsilon-greedy* sebagai strategi eksplorasi adaptif.
- Eksplorasi berbasis ketidakpastian model (*model uncertainty*) yang mengacu pada pendekatan *self-adjusting deep Q-learning* oleh Zhu dkk. [4].

5. Pengujian dilakukan melalui simulasi dengan beberapa skenario *workload*, yaitu kondisi stasioner sebagai pembanding, perubahan bertahap (*gradual shift*), perubahan mendadak (*sudden shift*), pola kedatangan tugas yang bersifat *bursty*, dan pola *Markov-modulated stochastic*.
6. Evaluasi kinerja dibatasi pada empat metrik, yaitu *task drop ratio*, *average delay*, *average cost*, dan *recovery time* setelah terjadi perubahan *workload*. Penelitian tidak membahas implementasi pada perangkat MEC nyata.

1.4 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Menganalisis pengaruh perubahan pola *workload non-stationary* terhadap kinerja algoritma LSTM-D3QN dalam melakukan *task offloading* pada lingkungan *Mobile Edge Computing*.
2. Membandingkan kinerja strategi *epsilon-greedy*, *adaptive epsilon-greedy*, dan eksplorasi berbasis ketidakpastian model (*model uncertainty*) dalam menghadapi perubahan *workload*.
3. Mengidentifikasi strategi eksplorasi yang memiliki kemampuan adaptasi terbaik berdasarkan metrik *task drop ratio*, *average delay*, *average cost*, dan *recovery time* setelah terjadi perubahan *workload*.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. **Manfaat Teoritis**

   Penelitian ini diharapkan dapat memberikan kontribusi terhadap pengembangan kajian *Deep Reinforcement Learning*, khususnya mengenai penerapan strategi eksplorasi adaptif untuk menghadapi perubahan *workload non-stationary* pada permasalahan *task offloading* di lingkungan *Mobile Edge Computing*. Selain itu, penelitian ini dapat menjadi referensi untuk penelitian selanjutnya yang membahas kemampuan adaptasi algoritma *Reinforcement Learning* dalam lingkungan yang dinamis.
2. **Manfaat Praktis**

   Penelitian ini diharapkan dapat memberikan gambaran mengenai pengaruh penggunaan strategi eksplorasi yang berbeda terhadap kinerja algoritma LSTM-D3QN dalam menghadapi perubahan *workload*. Hasil perbandingan dapat menjadi bahan pertimbangan dalam pemilihan strategi eksplorasi untuk meningkatkan kemampuan adaptasi sistem *task offloading*, terutama dalam

mengurangi *task drop ratio*, *average delay*, dan *average cost*, serta mempercepat pemulihan kinerja setelah terjadi perubahan *workload*.

1.6 Metodologi Penelitian

Metodologi yang digunakan dalam penelitian ini adalah metode eksperimental berbasis simulasi. Penelitian dilakukan melalui beberapa tahapan sebagai berikut:

1. **Studi Literatur**

   Mengumpulkan dan mempelajari literatur yang berkaitan dengan *Mobile Edge Computing*, *task offloading*, *Deep Reinforcement Learning*, lingkungan *non-stationary*, serta strategi *exploration–exploitation* sebagai dasar dalam perancangan penelitian.

2. **Perancangan Lingkungan Simulasi**

   Merancang lingkungan simulasi *Mobile Edge Computing* yang terdiri dari beberapa perangkat pengguna (*mobile devices*) dan sumber daya komputasi *edge* (*edge nodes*). Sistem menerapkan skema terdistribusi (*distributed DRL*) di mana setiap perangkat pengguna bertindak sebagai agen independen yang mengambil keputusan *task offloading* berdasarkan observasi lokalnya. Lingkungan simulasi dirancang untuk menghasilkan beberapa pola *workload*, baik stasioner maupun non-stasioner.

3. **Implementasi Algoritma**

   Mengimplementasikan algoritma LSTM-D3QN dengan tiga strategi eksplorasi yang berbeda, yaitu *epsilon-greedy*, *adaptive epsilon-greedy*, dan eksplorasi berbasis ketidakpastian model (*model uncertainty*). Arsitektur jaringan dan parameter pembelajaran utama dipertahankan sama agar perbandingan berfokus pada strategi eksplorasi.

4. **Pengujian dan Pengumpulan Data**

   Melakukan eksperimen terhadap setiap strategi eksplorasi pada beberapa skenario *workload*, meliputi kondisi stasioner, perubahan bertahap (*gradual*

shift), perubahan mendadak (*sudden shift*), pola kedatangan tugas *bursty*, dan pola *Markov-modulated stochastic*. Hasil setiap eksperimen dicatat untuk keperluan analisis.

5. **Analisis dan Evaluasi Hasil**

   Menganalisis hasil eksperimen berdasarkan metrik *task drop ratio*, *average delay*, *average cost*, dan *recovery time*. Hasil pengujian kemudian dibandingkan untuk mengetahui pengaruh masing-masing strategi eksplorasi terhadap kinerja dan kemampuan adaptasi algoritma LSTM-D3QN dalam menghadapi perubahan *workload*.

6. **Penarikan Kesimpulan**

   Menarik kesimpulan berdasarkan hasil analisis untuk menjawab rumusan masalah dan menentukan strategi eksplorasi yang menunjukkan kemampuan adaptasi terbaik pada skenario pengujian.

1.7 Sistematika Penulisan

Sistematika penulisan dalam penelitian ini disusun ke dalam lima bab dengan uraian sebagai berikut:

BAB I PENDAHULUAN

Bab ini membahas latar belakang penelitian, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

BAB II TINJAUAN PUSTAKA

Bab ini membahas teori dan konsep yang menjadi dasar penelitian, meliputi *Mobile Edge Computing*, *task offloading*, *Reinforcement Learning*, *Deep Reinforcement Learning*, arsitektur LSTM-D3QN, strategi *exploration–exploitation*, serta penelitian terdahulu yang relevan.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan tahapan penelitian secara terperinci, meliputi perancangan lingkungan simulasi, pemodelan sistem *task offloading*, implementasi algoritma

LSTM-D3QN, penerapan strategi eksplorasi, skenario pengujian *workload*, serta metrik evaluasi yang digunakan.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil pengujian dan analisis kinerja setiap strategi eksplorasi pada berbagai skenario *workload*. Pembahasan difokuskan pada perbandingan *task drop ratio*, *average delay*, *average cost*, dan *recovery time* untuk mengevaluasi kemampuan adaptasi algoritma terhadap perubahan *workload*.

BAB V KESIMPULAN DAN SARAN

Bab ini berisi kesimpulan berdasarkan hasil penelitian untuk menjawab rumusan masalah serta saran yang dapat digunakan sebagai bahan pengembangan dan penelitian selanjutnya.

DAFTAR PUSTAKA

[1] A. Yousefpour, C. Fung, T. Nguyen, dkk., "All one needs to know about fog computing and related edge computing paradigms: A complete survey," *Journal of Systems Architecture*, vol. 98, hlm. 289–330, 2019.

[2] A. Acheampong, Y. Zhang, X. Xu, dan D. A. Kumah, "A review of the current task offloading algorithms, strategies and approach in edge computing systems," *Computer Modeling in Engineering & Sciences*, vol. 134, no. 1, hlm. 35–88, 2023.

[3] M. Tang dan V. W. S. Wong, "Deep reinforcement learning for task offloading in mobile edge computing systems," *IEEE Transactions on Mobile Computing*, vol. 21, no. 6, hlm. 1984–1997, 2022.

[4] J. Zhu, Y. Wei, Y. Kang, X. Jiang, dan G. E. Dullerud, "Adaptive deep reinforcement learning for non-stationary environments," *Science China Information Sciences*, vol. 65, no. 7, 172201, 2022.

[5] A. Kumar dan D. Singh, "Adaptive Epsilon Greedy Reinforcement Learning Method in Securing IoT Devices in Edge Computing," *Discover Internet of Things*, vol. 4, no. 1, hlm. 1–15, 2024.